# Optimization Report

2300010816　　谭雪贻　　数学科学学院

2026 年 10 月 18 日

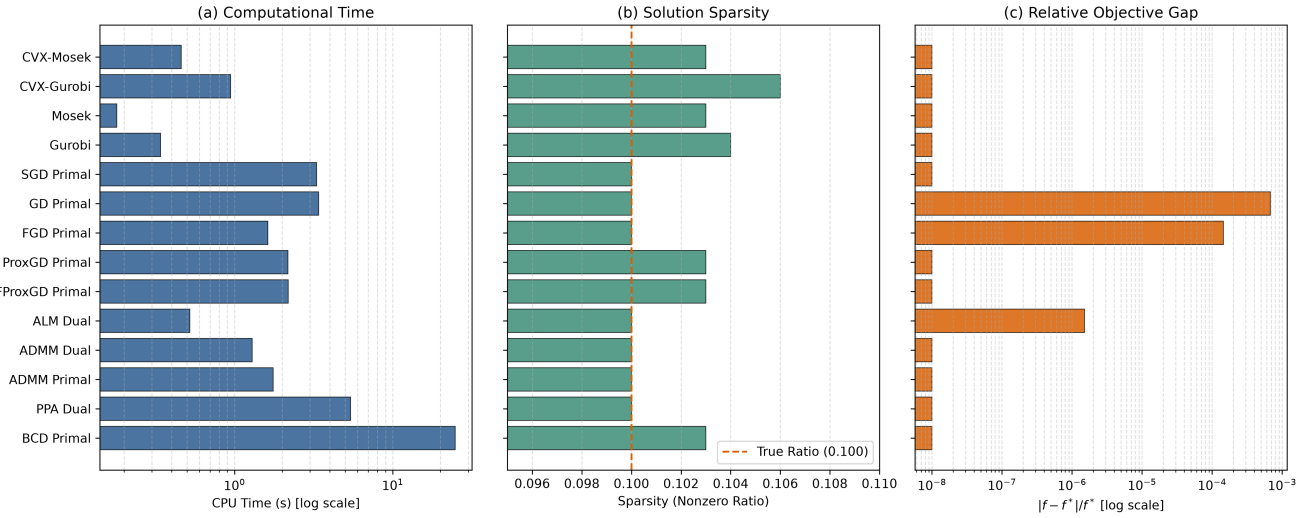
随机种子 97006855，实验结果统计见表1，具体输出见终端模块，所有图像见附录A。

表 1: Group LASSO 各求解器数值实验结果对比

| Solver | optval | sparsity | cpu / s | iter | err-exact | err-cvx-mosek | err-cvx-gurobi |
|---|---|---|---|---|---|---|---|
| CVX-Mosek | 6.70575e-01 | 0.103 | 0.46 | 9 | 3.19e-05 | 0.00e+00 | 1.14e-06 |
| CVX-Gurobi | 6.70575e-01 | 0.106 | 0.94 | 8 | 3.28e-05 | 1.14e-06 | 0.00e+00 |
| Mosek | 6.70575e-01 | 0.103 | 0.18 | 10 | 3.18e-05 | 1.70e-07 | 1.28e-06 |
| Gurobi | 6.70575e-01 | 0.104 | 0.34 | 9 | 3.20e-05 | 2.26e-07 | 1.02e-06 |
| SGD Primal | 6.70575e-01 | 0.100 | 3.29 | 15000 | 3.37e-05 | 2.41e-06 | 1.99e-06 |
| GD Primal | 6.71027e-01 | 0.100 | 3.40 | 10000 | 2.24e-04 | 1.94e-04 | 1.93e-04 |
| FGD Primal | 6.70672e-01 | 0.100 | 1.62 | 5000 | 1.18e-04 | 8.76e-05 | 8.66e-05 |
| ProxGD Primal | 6.70575e-01 | 0.103 | 2.17 | 7500 | 3.18e-05 | 2.30e-07 | 1.32e-06 |
| FProxGD Primal | 6.70575e-01 | 0.103 | 2.18 | 7500 | 3.18e-05 | 2.30e-07 | 1.32e-06 |
| ALM Dual | 6.70576e-01 | 0.100 | 0.52 | 500 | 3.05e-05 | 7.86e-06 | 8.25e-06 |
| ADMM Dual | 6.70575e-01 | 0.100 | 1.29 | 2000 | 3.21e-05 | 1.28e-06 | 1.79e-06 |
| ADMM Primal | 6.70575e-01 | 0.100 | 1.75 | 2000 | 3.21e-05 | 1.28e-06 | 1.79e-06 |
| PPA Dual | 6.70575e-01 | 0.100 | 5.40 | 500 | 3.17e-05 | 1.18e-06 | 1.89e-06 |
| BCD Primal | 6.70575e-01 | 0.103 | 24.71 | 3940 | 3.18e-05 | 2.30e-07 | 1.32e-06 |

```
1      CVX-Mosek: cpu:  0.46s, iter:     9, optval: 6.70575e-01, sparsity: 0.103, err-to
    -exact: 3.19e-05, err-to-cvx-mosek: 0.00e+00, err-to-cvx-gurobi: 1.14e-06
2      CVX-Gurobi: cpu:  0.94s, iter:     8, optval: 6.70575e-01, sparsity: 0.106, err-to
    -exact: 3.28e-05, err-to-cvx-mosek: 1.14e-06, err-to-cvx-gurobi: 0.00e+00
3           Mosek: cpu:  0.18s, iter:    10, optval: 6.70575e-01, sparsity: 0.103, err-to
    -exact: 3.18e-05, err-to-cvx-mosek: 1.70e-07, err-to-cvx-gurobi: 1.28e-06
4          Gurobi: cpu:  0.34s, iter:     9, optval: 6.70575e-01, sparsity: 0.104, err-to
    -exact: 3.20e-05, err-to-cvx-mosek: 2.26e-07, err-to-cvx-gurobi: 1.02e-06
5      SGD Primal: cpu:  3.29s, iter: 15000, optval: 6.70575e-01, sparsity: 0.100, err-to
    -exact: 3.37e-05, err-to-cvx-mosek: 2.41e-06, err-to-cvx-gurobi: 1.99e-06
6      GD Primal: cpu:  3.40s, iter: 10000, optval: 6.71027e-01, sparsity: 0.100, err-to
    -exact: 2.24e-04, err-to-cvx-mosek: 1.94e-04, err-to-cvx-gurobi: 1.93e-04
7      FGD Primal: cpu:  1.62s, iter:  5000, optval: 6.70672e-01, sparsity: 0.100, err-to
    -exact: 1.18e-04, err-to-cvx-mosek: 8.76e-05, err-to-cvx-gurobi: 8.66e-05
8   ProxGD Primal: cpu:  2.17s, iter:  7500, optval: 6.70575e-01, sparsity: 0.103, err-to
    -exact: 3.18e-05, err-to-cvx-mosek: 2.30e-07, err-to-cvx-gurobi: 1.32e-06
```

```
FProxGD Primal: cpu:  2.18s, iter:  7500, optval: 6.70575e-01, sparsity: 0.103, err-to-exact: 3.18e-05, err-to-cvx-mosek: 2.30e-07, err-to-cvx-gurobi: 1.32e-06
   ALM Dual: cpu:  0.52s, iter:   500, optval: 6.70576e-01, sparsity: 0.100, err-to-exact: 3.05e-05, err-to-cvx-mosek: 7.86e-06, err-to-cvx-gurobi: 8.25e-06
  ADMM Dual: cpu:  1.29s, iter:  2000, optval: 6.70575e-01, sparsity: 0.100, err-to-exact: 3.21e-05, err-to-cvx-mosek: 1.28e-06, err-to-cvx-gurobi: 1.79e-06
 ADMM Primal: cpu:  1.75s, iter:  2000, optval: 6.70575e-01, sparsity: 0.100, err-to-exact: 3.21e-05, err-to-cvx-mosek: 1.28e-06, err-to-cvx-gurobi: 1.79e-06
   PPA Dual: cpu:  5.40s, iter:   500, optval: 6.70575e-01, sparsity: 0.100, err-to-exact: 3.17e-05, err-to-cvx-mosek: 1.18e-06, err-to-cvx-gurobi: 1.89e-06
  BCD Primal: cpu: 24.71s, iter:  3940, optval: 6.70575e-01, sparsity: 0.103, err-to-exact: 3.18e-05, err-to-cvx-mosek: 2.30e-07, err-to-cvx-gurobi: 1.32e-06
```




**原生 SOCP）**

- Mosek（0.18s, 10 iters）与 Gurobi（0.34s, 9 iters）体现内点法收敛速度与稳定性，仅需约 10 步即达到 $10^{-8}$ 级别的内点互补松紧度。
- 对比 CVXPY 版本，高层建模框架解析转换带来额外时间开销（CVX-Gurobi 达 0.94s）

**近端梯度类算法（ProxGD、FProxGD 与 BCD）**

- 针对非光滑 $L_{1,2}$ 范数，基于近端映射算法表现较好，目标值均精准收敛至基准最优解 0.670575，与基准解误差低至 $2.30 \times 10^{-7}$。
- 连续化策略的加速下，ProxGD 与 FProxGD 耗时约为 2.17s；BCD Primal 虽单次遍历收敛准，但因逐行串行扫描，循环解释开销较大（24.71s）。

**平滑化与次梯度类算法（SGD、GD、FGD）**

- 次梯度法结合重球动量与延迟衰减步长后成功收敛至最优目标值，但由于次梯度震荡特性，迭代至 15,000 仍未收敛（但结果已很少稳定）。
- Huber 平滑类算法（GD Primal 与 FGD Primal）：目标值收敛至 0.671027 与 0.670672，相对误差在 $10^{-4}$ 量级。说明平滑近似误差对最终解精度限制；FGD 引入 Nesterov 动量后，迭代步数（5,000 iters）与计算耗时（1.62s）较 GD（10,000 iters, 3.40s）缩减 50%。

**对偶与算子分裂算法（ALM Dual、ADMM Dual/Primal、PPA Dual）**

- ALM Dual 仅用 500 次外层迭代和 0.52s 逼近全局最优解。
- ADMM Dual（1.29s）与 ADMM Primal（1.75s）预先对系数矩阵 $(I+tAA^T)$ 和 $(A^TA+\beta I)$ 做 Cholesky 分解，将内层线性系统求解降维为回代，指标收敛且与基准解误差在 $1.28\times10^{-6}$ 区间。

**算法解的稀疏性还原** 所有算法解非零行占比均高度收敛在真解比例（即 10%）附近。

# 1 CVX 基准模型

作为对照组，用 CVXPY 建模，分别调用 Mosek 和 Gurobi 内点法求解器，作为后续算法判断收敛精度、稀疏度还原及计算效率评判标准。

# 2 转化为二阶锥规划 SOCP 模型

原问题为无约束复合优化问题：

$$\min_x \frac{1}{2}\|Ax-b\|_F^2+\mu\sum_{i=1}^{n}\|x(i,:)\|_2$$

将目标函数变为纯线性，复杂运算转移到二阶锥约束中。先处理 Group LASSO 惩罚项，由于原问题 $\sum_{i=1}^{n}\|x(i,:)\|_2$ 非光滑，引入 $n$ 个辅助变量 $t=[t_1,\cdots,t_n]^\top\geq0$，将正则项替换为 $\mu\sum_{i=1}^{n}t_i$，同时对解矩阵 $X$ 每行施加惩罚上限约束

$$\|X_{i,:}\|_2\leq t_i,\quad i=1,\cdots,n$$

在数学上等价于要求向量 $(t_i,X_{i,1},\cdots,X_{i,l})$ 须在一个标准二阶锥内。再处理平方残差项（旋转二阶锥），原问题包含矩阵 Frobenuis 范数平方 $\|Ax-b\|_F^2$，引入辅助残差矩阵 $R\in\mathbb{R}^{m\times l}$ 和标量 $t_0\in\mathbb{R}$。令 $R=AX-b$，并要求 $\frac{1}{2}\|R\|_F^2\leq t_0$，由于 $\|R\|_F^2=\sum_{i=1}^{m}\sum_{j=1}^{l}R_{ij}^2$，该约束可改写为

$$2\cdot t_0\cdot1\geq\sum_{i=1}^{m}\sum_{j=1}^{l}R_{ij}^2,\quad \frac{1}{2}\|R\|_F^2\leq t_0$$

由于 $\|R\|_F^2=\sum_{j,k}R_{jk}^2$，上述约束可改写为 $2\cdot t_0\cdot1\geq\sum R_{jk}^2$。形式为 $2y_1y_2\geq\sum z_i^2$ 且 $y_1,y_2\geq0$ 的空间，是旋转二阶锥。综上，最终 SOCP 模型：

$$\begin{aligned}
\min_{x,R,t_0,t}\quad & t_0+\mu\sum_{i=1}^{n}t_i\\
\text{s.t.}\quad & R=AX-b\\
& \sum_{j=1}^{l}X_{ij}^2\leq t_i^2,\quad i=1,\cdots,n\\
& \sum R_{jk}^2\leq 2t_0\\
& t_0\geq0,\quad t\geq0
\end{aligned}$$

# 3 各类算法

## (a) 次梯度算法 SGD

根据次梯度迭代框架，$X^{(k)}=X^{k-1}-t_kG^{(k-1)}$，先求目标函数次梯度。原问题无约束目标函数为

$$F(X)=\frac{1}{2}\|Ax-b\|_F^2+\mu\sum_{i=1}^{n}\|x(i,:)\|_2$$

可将目标函数拆分为光滑数据拟合项 $g(X)=\frac{1}{2}\|Ax-b\|_F^2$ 和非光滑正则项 $h(X)=\mu\sum_{i=1}^{n}\|x(i,:)\|_2$。

1. 光滑项梯度：拟合项 $g(X)$ 为二次可微凸函数，其梯度由矩阵求导得

$$\nabla g(X)=A^\top(AX-b)$$

2. 非光滑项次梯度：正则项 $h(X)$ 包含 $L_{1,2}$ 范数（即各行 $L_2$ 范数和），在行向量全为 0 时不可微，对矩阵 $X$ 第 $i$ 行 $X_{i,:}$ 独立求次梯度，记作 $v_i\in\mathbb{R}^{1\times l}$：
   - 当 $\|X_{i,:}\|_2>0$ 时，范数在该处可导，次梯度唯一：$v_i=\frac{X_{i,:}}{\|X_{i,:}\|_2}$；
   - 当 $\|X_{i,:}\|_2=0$ 时，次梯度是单位球内的任意向量集合：$v_i\in\{z\mid\|z\|_2\le 1\}$。

   实际算法中为简化计算并保持对称性，当分母为 0 时（体现为行范数小于保护阈值 $\|X_{i,:}\le 10^{-12}$），直接取次梯度 $v_i=0$。
3. 总体次梯度与迭代：综上，目标函数总体次梯度矩阵 $G\in\partial F(X)\subseteq\mathbb{R}^{n\times l}$ 为

$$G=A^\top(AX-b)+\mu V$$

   其中次梯度分量矩阵 $V\in\mathbb{R}^{n\times l}$ 的第 $i$ 行定义为

$$V_{i,:}=\begin{cases}\frac{X_{i,:}}{\|X_{i,:}\|_2}, & \|X_{i,:}\|_2>0\\ 0, & \|X_{i,:}\|_2=0\end{cases}$$

   由此得到次梯度法完整迭代格式

$$X^{(k+1)}=X^{(k)}-t_kG^{(k)}$$

   由于次梯度法非严格单调下降算法（极小点处会锯齿震荡），算法在迭代过程中实时追踪并保存历史最优目标函数值 $F_{\text{best}}^{(k)}=\min_{0\le i\le k}F(X^{(i)})$ 及其对应最优解 $X_{\text{best}}$。
4. 连续化步长、动量消震等处理：
   - 平滑指数连续化与分段衰减步长（连续化）：算法令正则化系数从初值 $\mu_0=500\mu$ 按衰减率 $\gamma=0.999$ 逐轮平滑衰减至 $\mu$（$\mu_t\leftarrow\max(\mu,\gamma\mu_t)$）当 $\mu_t>\mu$ 时，采用固定步长 $t_k=\frac{1}{\lambda_{\max}(A^\top A)}$ 进行快速热启动；当 $\mu_t=\mu$ 时，用延迟衰减步长 $t_k=\frac{1}{\lambda_{\max}(A^\top A)(\max\{k_{sub},100\}-99)}$，从而在后期逼近极小值。
   - 重球动量消震：针对次梯度在非光滑尖点附近剧烈法向震荡，迭代中引入惯性动量项 $\beta(X^{(k)}-X^{(k-1)})$，使相反方向的法向次梯度相互抵消，沿极小值谷方向加速。
   - 稀疏化硬阈值后处理：由于次梯度更新缺乏近端软阈值截断，算法在输出历史最优解 $X_{\text{best}}$ 前用分位数硬阈值后处理，剔除参与浮点噪声行以还原组稀疏度。

## (b) 梯度下降法 GD Primal

利用 Nesterov 光滑技术将不可微目标函数替换为带光滑参数的处处可微近似函数，从而调用梯度下降法。

1. Nesterov 共轭光滑化 Huber 惩罚函数：Group LASSO 正则项中包含非光滑行 2-范数 $\|z\|_2$（其中 $z\in\mathbb{R}^{1\times l}$ 代表 $X$ 某一行），根据共轭函数性质与对偶范数定义，2-范数可表示为单位球上线性函数上确界：

$$\|z\|_2=\sup_{\|y\|_2=1}\langle z,y\rangle$$

   通过引入强凸函数为 1 邻近函数 $d(y)=\frac{1}{2}\|y\|_2^2$，可构造带光滑参数 $\mu_s>0$ 平滑近似函数 $\phi_{\mu_s}(z)$：

$$\phi_{\mu_s}(z)=\sup_{\|y\|_2=1}\left(\langle z,y\rangle-\frac{\mu_s}{2}\|y\|_2^2\right)$$

   通过解析求解该球约束下二次规划上确界（当 $\|z\|_2\le\mu_s$ 时极值点在球内 $y^*=z/\mu_s$；当 $\|z\|_2>\mu_s$ 时极值点在球面边界 $y^*=z/\|z\|_2$），可得 Huber 惩罚函数多维形式：

$$\phi_{\mu_s}(z)=\begin{cases}\frac{\|z\|_2^2}{2\mu_s}, & \|z\|_2\le\mu_s\\ \|z\|_2-\frac{\mu_s}{2}, & \|z\|_2>\mu_s\end{cases}$$

2. 光滑化目标函数与全局梯度：将原问题中行-2 范数替换为 $\phi_{\mu_s}$，光滑化后问题目标函数为处处可微的

$$F_{\mu_s}(X) = \frac{1}{2}\|AX - b\|_2^2 + \mu \sum_{i=1}^{n} \phi_{\mu_s}(X_{i,:})$$

根据平滑截断梯度矩阵 $V \in \mathbb{R}^{n\times l}$ 第 $i$ 行定义为

$$V_{i,:} = \nabla \phi_{\mu_s}(X_{i,:}) = \begin{cases} \frac{X_{i,:}}{\mu_s}, & \|X_{i,:}\|_2 \le \mu_s \\ \frac{X_{i,:}}{\|X_{i,:}\|_2}, & \|X_{i,:}\|_2 > \mu_s \end{cases}$$

3. Lipschitz 常数与迭代：由于函数 $\phi_{\mu_s}(z)$ 梯度为 $\frac{1}{\mu_s}$-Lipschitz 连续的，结合二次拟合项，平滑目标函数 $\nabla F_{\mu_s}(X)$ 的全局 Lipschitz 常数 $L$ 为

$$L = \lambda_{\max}(A^\top A) + \frac{\mu}{\mu_s} = \|A^\top A\|_2 + \frac{\mu}{\mu_s}$$

从而光滑化梯度下降法迭代格式为（理论固定步长取 $t_{\text{fixed}} = \frac{1}{L}$）

$$X^{(k+1)} = X^{(k)} - t_k \nabla F_{\mu_s}(X^{(k)})$$

4. 动态连续化、BB 步长与 Zhang-Hager 非单调线搜索：光滑化目标函数全局 Lipschitz 常数 $L$ 随 $\mu_s$ 减小而急剧增大，导致固定步长 $1/L$ 保守，故代码实现三种加速技术
   - 双参数联动连续化：令正则化参数 $\mu_t$ 从 $500\mu$ 指数衰减至 $\mu$，同时保持光滑参数 $\mu_s = 0.02\mu_t$ 动态缩放，为细粒度平滑问题提供初始解路径（Warm-start）。
   - Barzilai-Borwein 自适应步长：用相邻迭代点位移差 $S^{(k-1)} = X^{(k)} - X^{(k-1)}$ 与光滑梯度差 $Y^{(k-1)} = \nabla F\mu_s(X^{(k)}) - \nabla F_{\mu_s}(X^{(k-1)})$，交替使用拟牛顿割线步长估算局部曲率：

$$t_k^{BB1} = \frac{\langle S^{(k-1)}, S^{(k-1)}\rangle}{\langle S^{(k-1)}, Y^{(k-1)}\rangle}, \quad t_k^{BB2} = \frac{\langle S^{(k-1)}, Y^{(k-1)}\rangle}{\langle Y^{(k-1)}, Y^{(k-1)}\rangle}$$

   - Zhang-Hager 非单调线搜索与硬阈值后处理：BB 步长非单调，直接用严格单调约束会破坏跨越狭长山谷能力，故代码引入非单调线搜索，维护历史函数值指数加权平均 $C_k = \left(\eta Q_{k-1} C_{k-1} + F_{\mu_s}(X^{(k)})\right)/Q_k$，试探步违背非单调充分下降条件 $F_{\mu_s}(X^{(k)} - t_k G^{(k)}) \le C_k - \sigma t_k \|G^{(k)}\|_F^2$ 时执行步长回溯。最后用分位数硬阈值清除 Huber 二次平滑区内的浮点残余。

## (c) 快速梯度下降法 FGD Primal

在 GD 平滑目标函数 $F_{\mu_s}(X)$ 基础上引入 Nesterov 动量加速外推。由于 Huber 函数光滑化后光滑项 $h(x) = 0$，此时近端算子退化为恒等映射。迭代格式变为动量点 $Y$ 上执行纯梯度下降。迭代格式：

1. 动量外推计算 $Y$：

$$Y^{(k)} = X^{(k-1)} + \frac{k-2}{k+1}(X^{(k-1)} - X^{(k-2)})$$

2. 梯度下降更新 $X$：

$$X^{(k)} = Y^{(k)} - t\nabla F_{\mu_s}(Y^{(k)})$$

其中步长 $t = \frac{1}{L}$ 且 $L = \lambda_{\max}(A^\top A) + \frac{\mu}{\mu_s}$，$\nabla F_{\mu_s}(Y^{(k)})$ 为计算方式同 GD，仅将代入点由 $X$ 改为外推点 $Y$。重启机制与硬阈值后处理：Nesterov 动量在迭代后期易产生水波纹震荡，代码引入启发式重启：监测到目标函数值上升则清空动量（重置 $Y = X$），重新积累梯度。同时由于平滑化破坏产生绝对 0 次梯度结构，输出前用分位数硬阈值压制浮点误差。

## (d) 近端梯度法 ProxGD Primal

将目标函数拆分为可微光滑项 $g(X)$ 和不可微凸惩罚项 $h(X)$。其迭代格式由一个显式梯度下降步和一个隐式近端映射步组合：

$$X^{(k)} = \text{prox}_{t_k h}(X^{(k-1)} - t_k \nabla g(X^{(k-1)}))$$

1. 计算步长：步长取固定值 $t_k = \frac{1}{L}$，其中 $L$ 为光滑项梯度 Lipschitz 常数，由于 $g(X)$ 为二次拟合项，故 $L = \lambda_{\max}(A^\top A)$。
2. 梯度下降：在当前点沿光滑项负梯度方向走一步，得中间变量 $Z$

$$Z^{(k)} = X^{(k-1)} - t_k A^\top (AX^{(k-1)} - b)$$

3. 近端映射：用 $h(X)$ 近端算子对 $Z$ 映射，对 $L_{1,2}$ 范数，其近端算子表现为逐行块软阈值化操作（对 $Z$ 按行近端映射）

$$X_{i,:}^{(k)} = \text{prox}_{t_k\mu\|\cdot\|_2}(Z_{i,:}^{(k)}) = Z_{i,:}^{(k)} \max\left(1 - \frac{t_k\mu}{\|Z_{i,:}^{(k)}\|_2}, 0\right), \quad \forall i = 1, \cdots, n$$

固定步长 $t_k = 1/\lambda_{\max}(A^\top A)$。

同理，为加速初期收敛，阈值中 $\mu_t$ 采用由大到小连续化衰减。

## (e) 快速近端梯度法 (FISTA)FProxGD Primal

FISTA 在动量外推点上只对光滑项求梯度，后对非光滑项用近端算子（对应逐行块软阈值化）。迭代格式：

1. 动量外推：

$$Y^{(k)} = X^{(k-1)} + \frac{k-2}{k+1}(X^{(k-1)} - X^{(k-2)})$$

2. 光滑项梯度下降计算中间变量 $Z$：

$$Z^{(k)} = Y^{(k)} - t_k A^\top (AY^{(k)} - b)$$

3. 用近端映射更新 $X$：

$$X_{i,:}^{(k)} = \text{prox}_{t_k\mu\|\cdot\|_2}(Z_{i,:}^{(k)}) = Z_{i,:}^{(k)} \max\left(1 - \frac{t_k\mu}{\|Z_{i,:}^{(k)}\|_2}, 0\right), \quad \forall i = 1, \cdots, n$$

此处步长取 $t = 1/L$，其中 Lipschitz 常数仅由拟合项决定：$L = \lambda_{\max}(A^\top A)$。

代码用了带连续化与重启机制 FISTA，正则项系数 $\mu_t$ 指数衰减提供初始化路径；非单调震荡时重置动量。

## (f) 增广拉格朗日乘子法 ALM Dual

求解对偶问题：引入辅助变量 $Y$，构造等价形式

$$\min_{X,Y} \quad \mu\|X\|_{1,2} + \frac{1}{2}\|Y\|_F^2, \quad \text{s.t.} \quad AX - b - Y = 0$$

引入拉格朗日乘子矩阵 $\Lambda \in \mathbb{R}^{m\times l}$，构造拉格朗日函数

$$\mathcal{L}(X, Y, \Lambda) = \mu\|X\|_{1,2} + \frac{1}{2}\|Y\|_F^2 - \text{Tr}(\Lambda^\top (AX - b - Y))$$

分别对 $X$ 和 $Y$ 求极小推导对偶函数 $d(\Lambda)$：

- 对 $Y$ 求极小：$\min_Y \frac{1}{2}\|Y\|_F^2 - \text{Tr}(\Lambda^\top Y)$，是二次函数，极小值点为 $Y = -\Lambda$，代入得最小值 $-\frac{1}{2}\|\Lambda\|_F^2$。
- 对 $X$ 求极小：$\min_X \mu\|X\|_{1,2} - \text{Tr}((A^\top\Lambda)^\top X)$，由共轭范数原理，$L_{1,2}$ 范数对偶范数为 $L_{\infty,2}$（行范数最大值），要让极小值不为 $-\infty$，需满足 $\|A^\top\Lambda\|_{-\infty,2} \le \mu$，此时极小值为 0.

提出常数项 $\mathrm{Tr}(\Lambda^\top b)$，对偶函数为

$$d(\Lambda) = -\frac{1}{2}\|\Lambda\|_F^2 + \mathrm{Tr}(b^\top \Lambda)$$

将极大化对偶函数转化为极小化问题，则对偶问题为

$$\min_{\Lambda} \frac{1}{2}\|\Lambda\|_F^2 - \mathrm{Tr}(b^\top \Lambda) \quad \text{s.t.} \quad \|(A^\top \Lambda)_{i,:}\|_2 \le \mu, \quad \forall i = 1, \cdots, n$$

记约束集为 $C = \{Z \in \mathbb{R}^{n\times l} | \|Z_{i,:}\|_2 \le \mu\}$，引入辅助变量 $Z$，改写为

$$\min_{\Lambda, Z} \frac{1}{2}\|\Lambda\|_F^2 - \mathrm{Tr}(b^\top \Lambda) + \mathcal{J}_C(Z) \quad \text{s.t.} \quad A^\top \Lambda - Z = 0$$

下面用增广拉格朗日乘子法：引入惩罚参数 $t > 0$ 和乘子 $X$，

$$\mathcal{L}_t(\Lambda, Z, X) = \frac{1}{2}\|\Lambda\|_F^2 - \mathrm{Tr}(b^\top \Lambda) + \mathcal{J}_C(Z) + \mathrm{Tr}(X^\top (A^\top \Lambda - Z)) + \frac{t}{2}\|A^\top \Lambda - Z\|_F^2$$

ALM 要求在内层循环联合极小化 $\Lambda$ 和 $Z$：

$$(\Lambda^{(k+1)}, Z^{(k+1)}) = \arg\min_{\Lambda, Z} \mathcal{L}_t(\Lambda, Z, X^{(k)})$$
$$X^{(k+1)} = X^{(k)} + t(A^\top \Lambda^{(k+1)} - Z^{(k+1)})$$

由于无法直接联合极小化，故用 Moreau-Yosida 技巧，提前将 $Z$ 投影消去，将内层问题转化为关于 $\Lambda$ 无约束光滑可导问题：

$$F_k(\Lambda) = \frac{1}{2}\|\Lambda\|_F^2 - \mathrm{Tr}(b^\top \Lambda) + \frac{t}{2}\|V - \mathcal{P}_C(V)\|_F^2, \quad \text{其中} V = A^\top \Lambda + X^{(k)}/t$$

其梯度解析形式：$\nabla F_k(\Lambda) = \Lambda - b + tA(V - \mathcal{P}_C(V))$，可直接用 Scipy 中 L-BFGS-B 算法求解。

## (g) 交替方向乘子法 ADMM Dual

将 ALM 中联合极小化拆分为交替极小化，消除内层循环，得到解析解：

1. $\Lambda$ 更新（二次规划）：

$$\Lambda^{(k+1)} = \arg\min_{\Lambda} \frac{1}{2}\|\Lambda\|_F^2 - \mathrm{Tr}(b^\top \Lambda) + \frac{t}{2}\|A^\top \Lambda - Z^{(k)} + X^{(k)}/t\|_F^2$$

求导令其为 0 得到线性方程组：$(I + tAA^\top)\Lambda = b + tAZ^{(k)} - AX^{(k)}$，系数矩阵正定，进行 Cholesky 分解。

2. $Z$ 更新（投影）：

$$Z^{(k+1)} = \mathcal{P}_C(A^\top \Lambda^{(k+1)} + X^{(k)}/t)$$

即对矩阵逐行进行极简缩放截断：$Z_{i,:} = V_{i,:} \min\left(1, \frac{\mu}{\|V_{i,:}\|_2}\right)$，其中 $V = A^\top \Lambda^{(k+1)} - X^{(k)}/t$。

3. $X$ 更新（原变量恢复）：

$$X^{(k+1)} = X^{(k)} + t(A^\top \Lambda^{(k+1)} - Z^{(k+1)})$$

## (h) 交替方向乘子法 ADMM Primal

通过引入一致性辅助变量 $Z$ 改写为

$$\min_{X, Z} f(X) + h(Z), \quad \text{s.t.} \quad X - Z = 0$$

引入缩放形式对偶变量 $U$ 和惩罚参数 $\beta > 0$，定义增广拉格朗日

$$\mathcal{L}_\beta(X, Z, U) = f(X) + h(Z) + \frac{\beta}{2}\|X - Z + U\|_2^2$$

求解 $X^{(k+1)} = \arg\min_X \mathcal{L}_\beta(X, Z^{(k)}, U^{(k)})$。子问题是关于 $X$ 光滑二次优化，对 $X$ 求偏导并令为零：

$$\nabla_X \mathcal{L}_\beta = A^\top(AX - b) + \beta(X - Z^{(k)} + U^{(k)}) = 0$$

即得线性方程组 $(A^\top A + \beta I)X = A^\top b + \beta(Z^{(k)} - U^{(k)})$，系数矩阵固定，代码在初始化时做一次 Cholesky 分解，后续迭代只需三角回代（`cho_solve`）获得精确解：

1. $X$ 更新（Single Gradient Step）：关于 $X$ 偏导为 $G_X^{(k)} = \nabla f(X^{(k)}) + \beta(X^{(k)} - Z^{(k)} + U^{(k)}) = A^\top(AX^{(k)} - b) + \beta(X^{(k)} - Z^{(k)} + U^{(k)})$，令为 0，解线性方程组 $(A^\top A + \beta I)X = A^\top b + \beta(Z - U)$。
2. $Z$ 更新（Proximal Step）：

$$Z^{(k+1)} = \arg\min_Z \mu\|Z\|_{1,2} + \frac{\beta}{2}\|X^{(k+1)} - Z + U^{(k)}\|_F^2$$

是块软阈值化操作

$$Z_{i,:}^{(k+1)} = \max\left(1 - \frac{\mu/\beta}{\|X_{i,:}^{(k+1)} + U_{i,:}^{(k)}\|_2}, 0\right)(X_{i,:}^{(k+1)} + U_{i,:}^{(k)})$$

3. $U$ 更新（Dual Update）：

$$U^{(k+1)} = U^{(k)} + X^{(k+1)} - Z^{(k+1)}$$

## (i) 近似点算法 PPA Dual

其实等价于对原问题使用增广拉格朗日乘子法 ALM。引入辅助变量 $Y$，

$$\mathcal{L}_t(X, Y, \Lambda) = \mu\|X\|_{1,2} + \frac{1}{2}\|Y - b\|_F^2 - \mathrm{Tr}(\Lambda^\top(AX - Y)) + \frac{t}{2}\|AX - Y\|_F^2$$

要在内层循环联合极小化 $X$ 和 $Y$。令 $\nabla_Y \mathcal{L}_t = (Y - b) - \Lambda - t(AX - Y) = 0$，得到 $Y$ 解析解：

$$Y = \frac{b + \Lambda + tAX}{1 + t}$$

约束取 $AX - Y = 0$，将 $Y$ 代回 $\mathcal{L}_t$，得到关于 $X$ 内层无约束子问题

$$\min_X \quad \mu\|X\|_{1,2} + \frac{t}{2(1+t)}\|AX - (b - \Lambda/t)\|_F^2$$

## (j) 块坐标下降法 BCD Primal

每次只优化一个变量块，固定其他变量不变。将 $X$ 每行 $x_i = X_{i,:}$ 作为一个变量块。设矩阵 $A$ 的第 $i$ 列为 $a_i$，将其余行固定残差记为 $R_{\neq i} = R - a_i x_i^{(old)}$。针对 $x_i$ 优化目标为

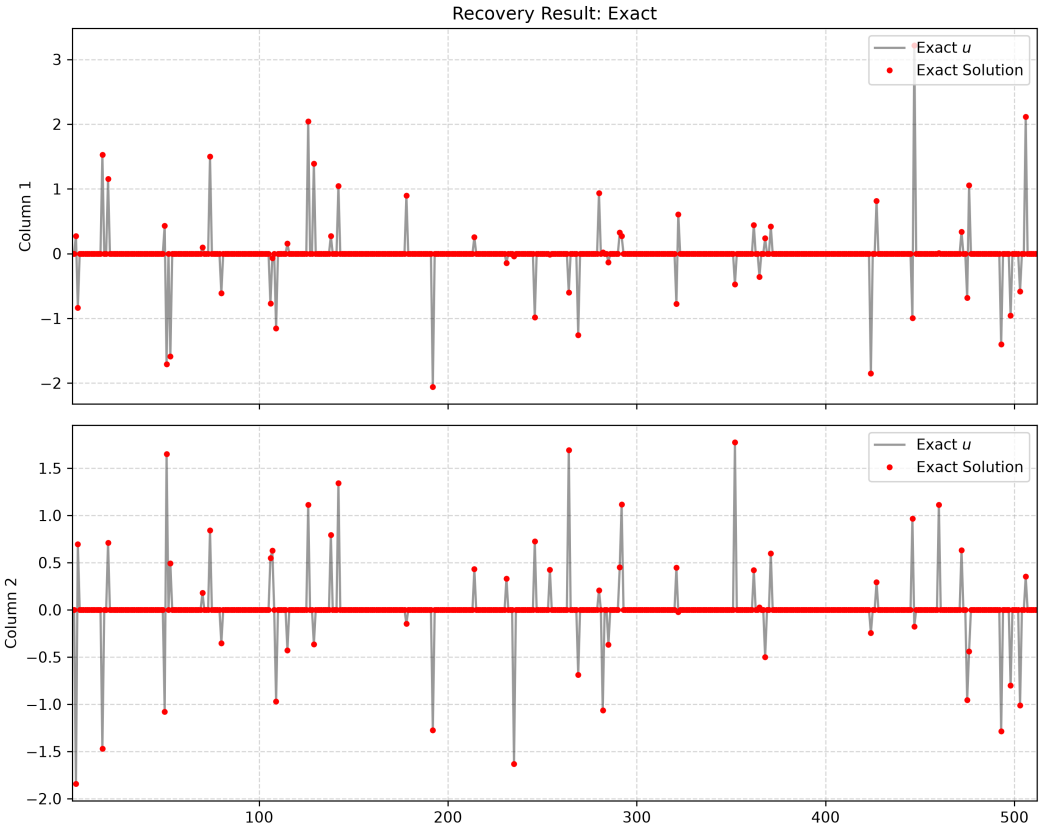
$$\min_{x_i} \frac{1}{2}\|a_i x_i + R_{\neq i}\|_2^2 + \mu\|x_i\|_2$$

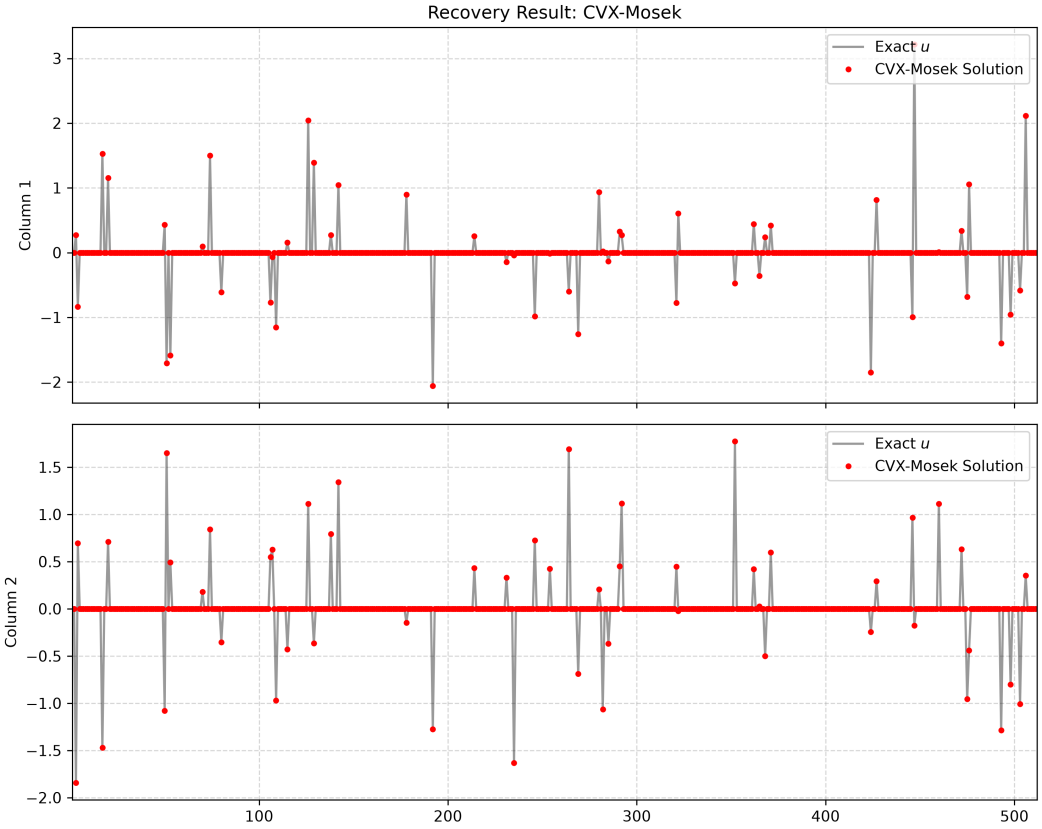
是一维 Proximal 映射，有闭式解（闭式软阈值），令辅助向量 $w_i = x_i^{(old)} - \frac{a_i^\top R}{\|a_i\|_2^2}$，则

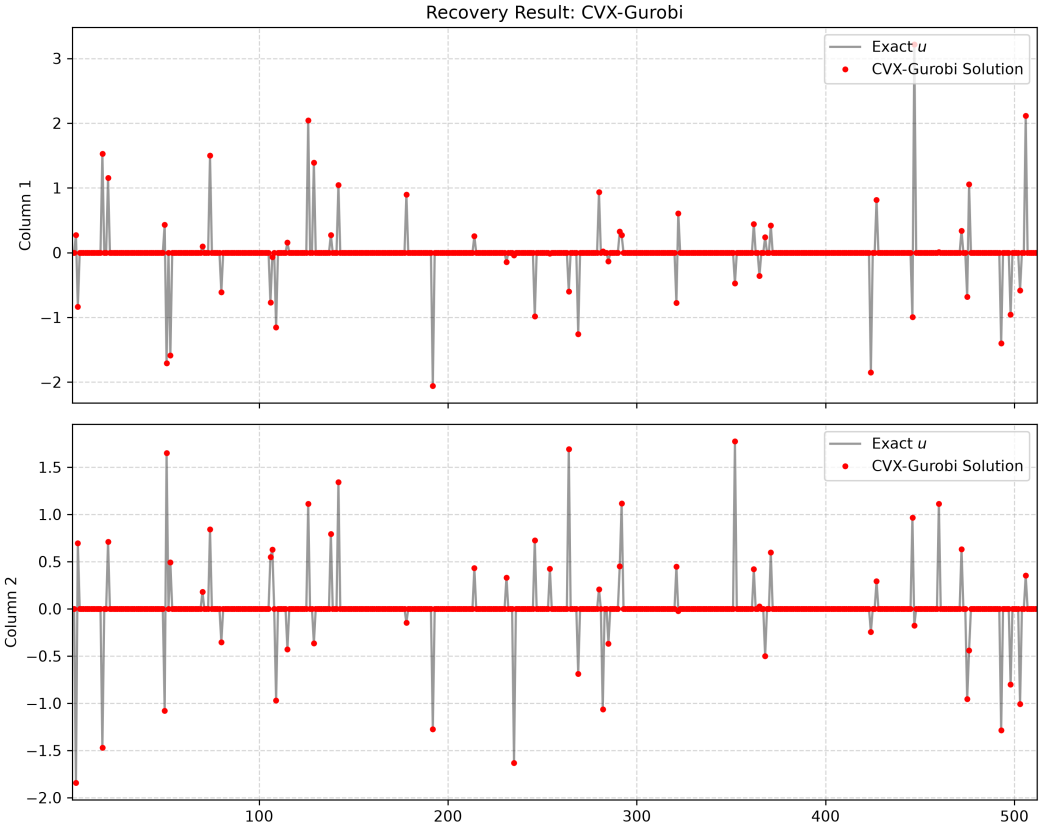
$$x_i^{(new)} = \max\left(1 - \frac{\mu/\|a_i\|_2^2}{\|w_i\|_2}, 0\right) w_i$$

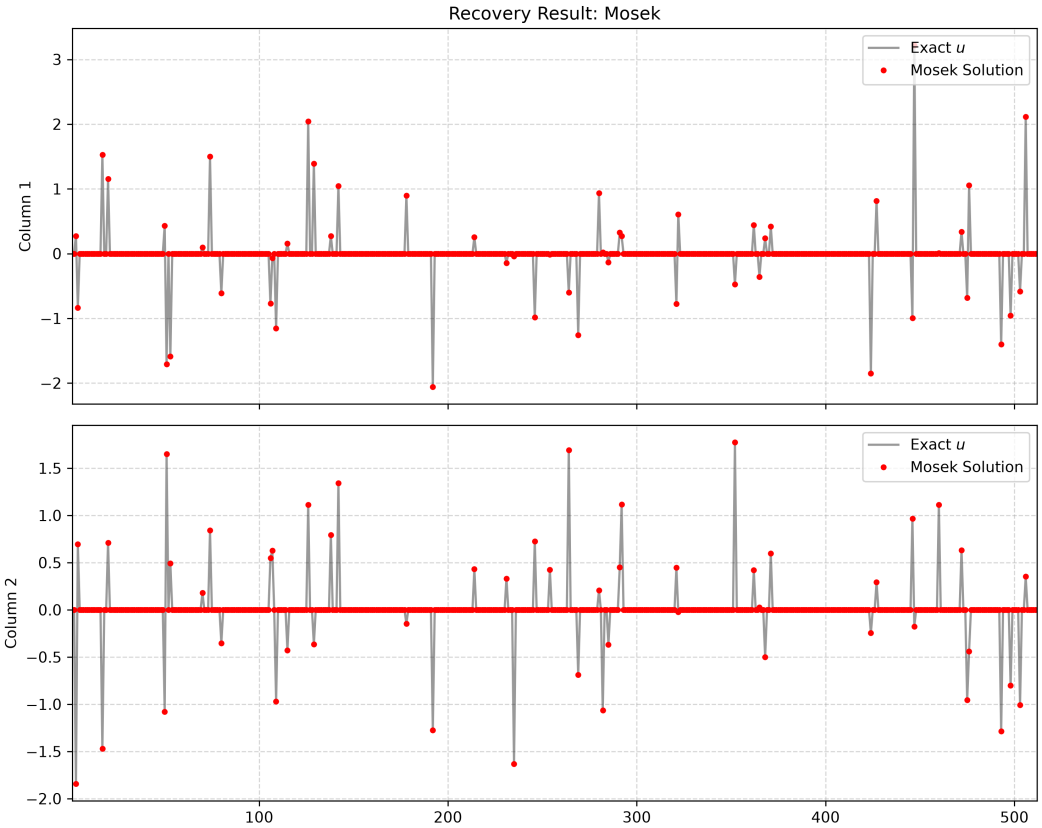
无需内层循环或矩阵求逆，只需遍历每行更新 $x_i$，并同步更新残差 $R \leftarrow R + a_i\left(x_i^{(new)} - x_i^{(old)}\right)$ 即可。代码中融合参数连续化，通过赋予罚参数 $\mu_t$ 较大初值并逐轮衰减，前期以大阈值快速清除非支撑集，后期细调。

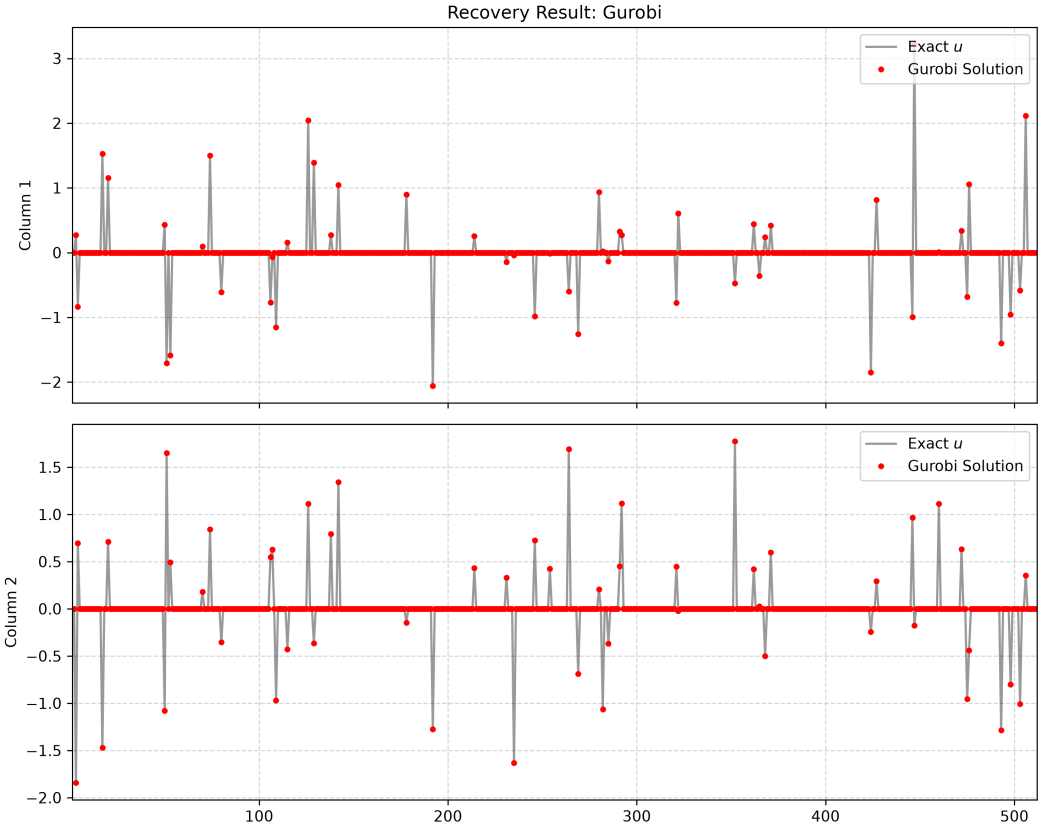
# A 输出图像

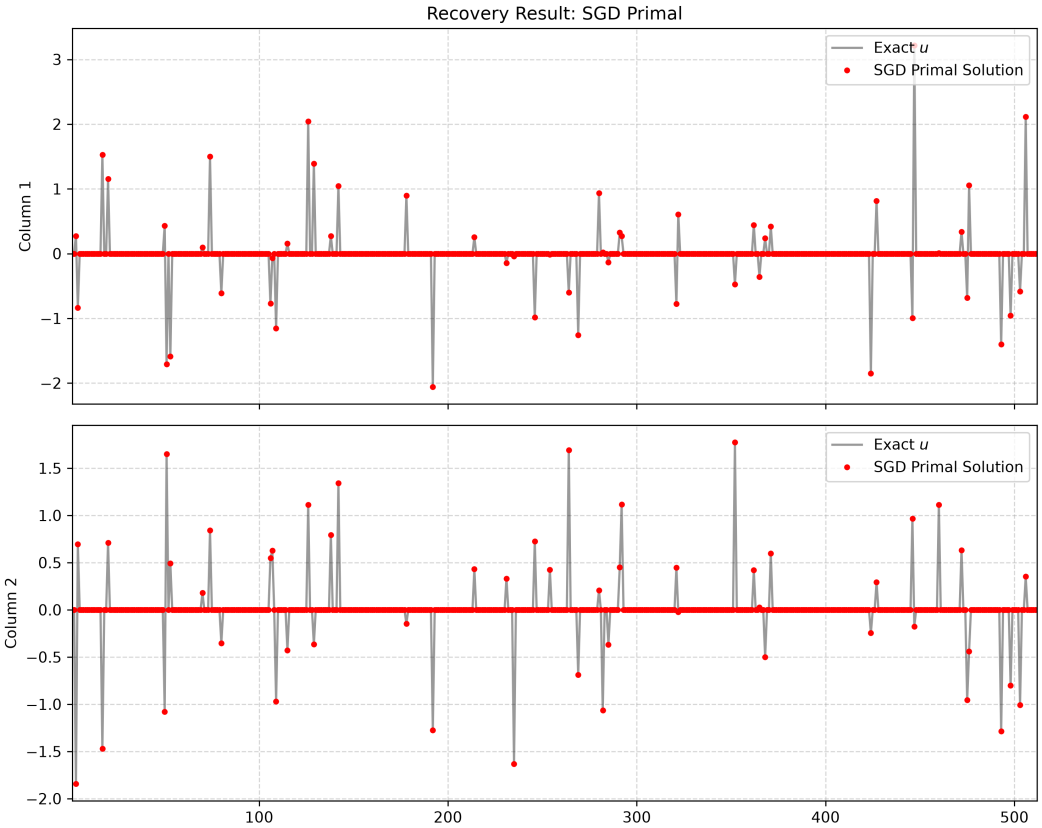

Recovery Result: Exact
Exact u
Exact Solution
Column 1
Column 2
100
200
300
400
500

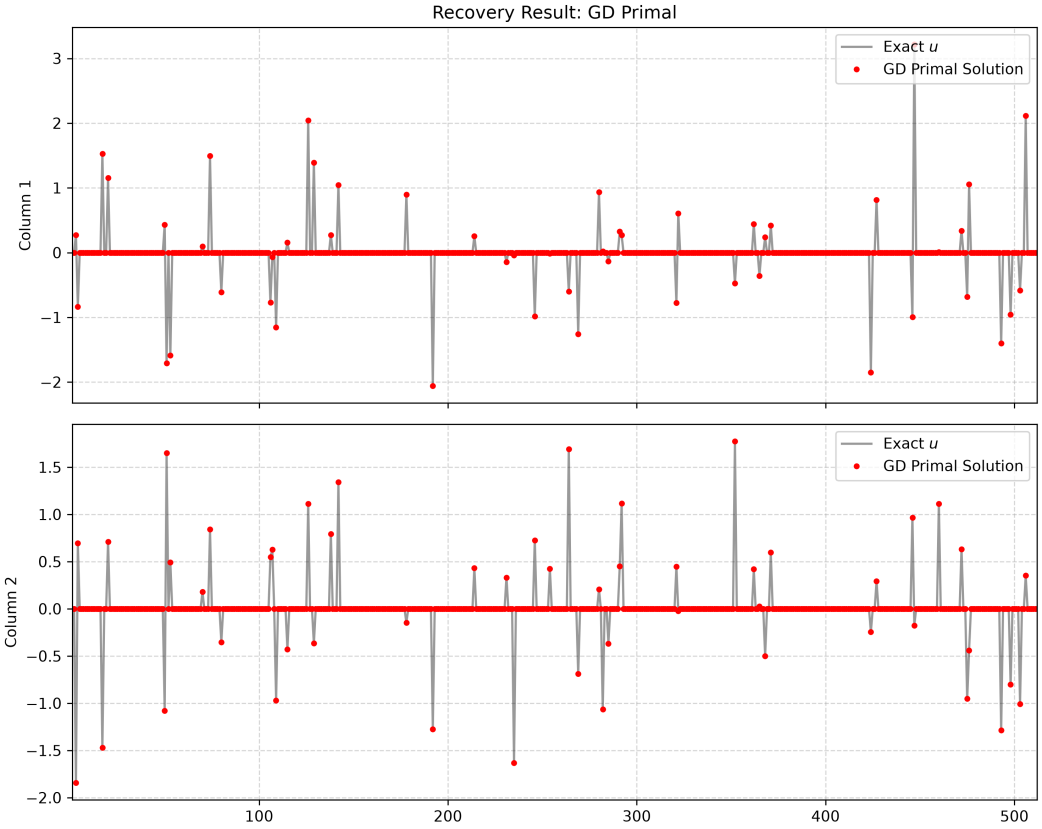

Recovery Result: CVX-Mosek
Exact u
CVX-Mosek Solution
Column 1
Column 2
100
200
300
400
500

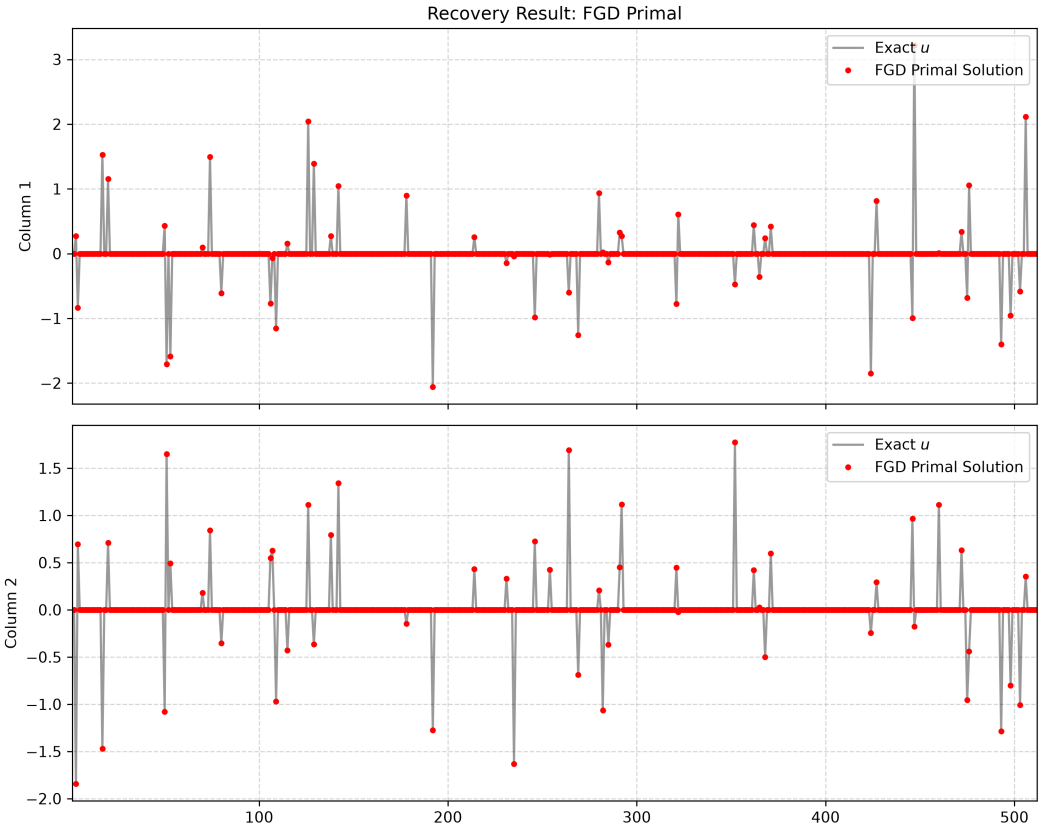

Recovery Result: CVX-Gurobi
Exact u
CVX-Gurobi Solution
Column 1
Column 2

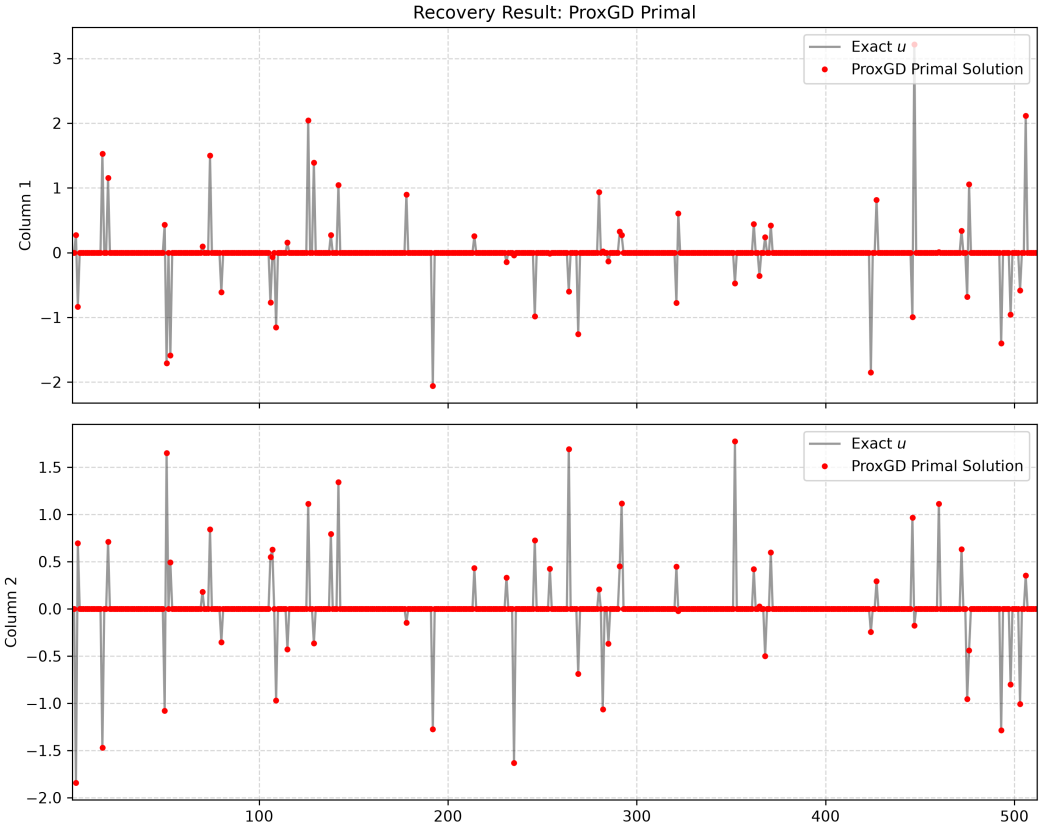

Recovery Result: Mosek
Exact u
Mosek Solution
Column 1
Column 2

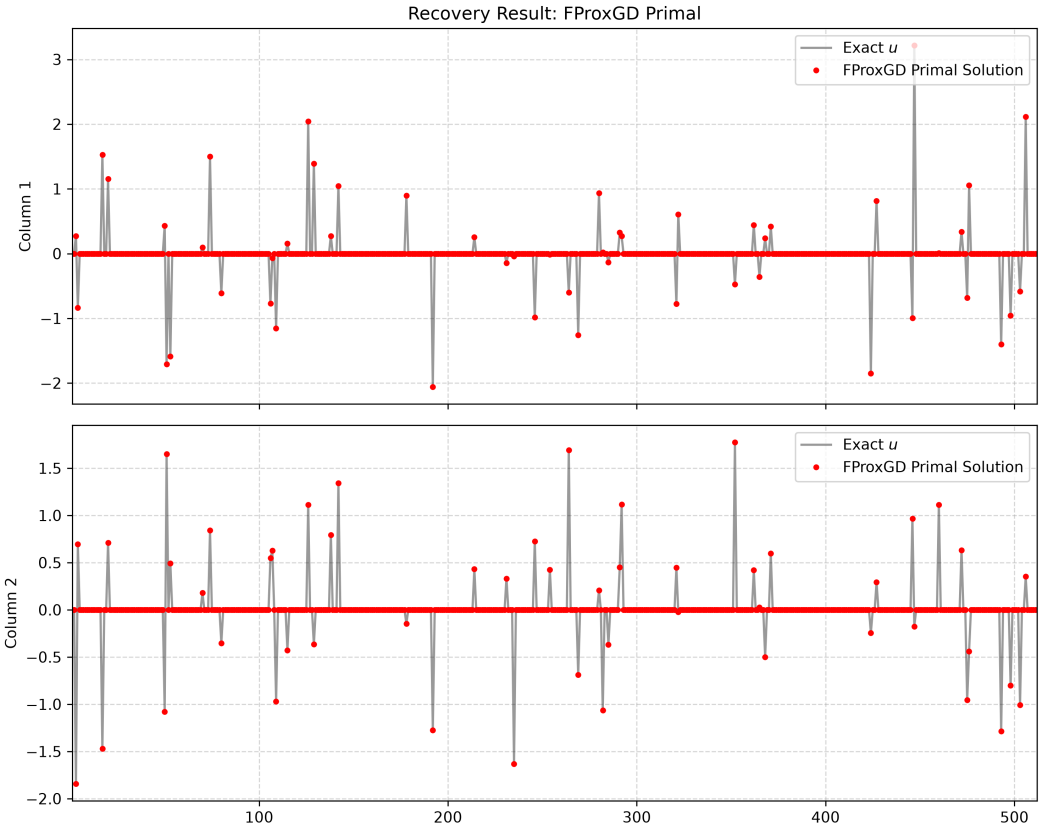

Recovery Result: Gurobi
Exact u
Gurobi Solution
Column 1
Column 2

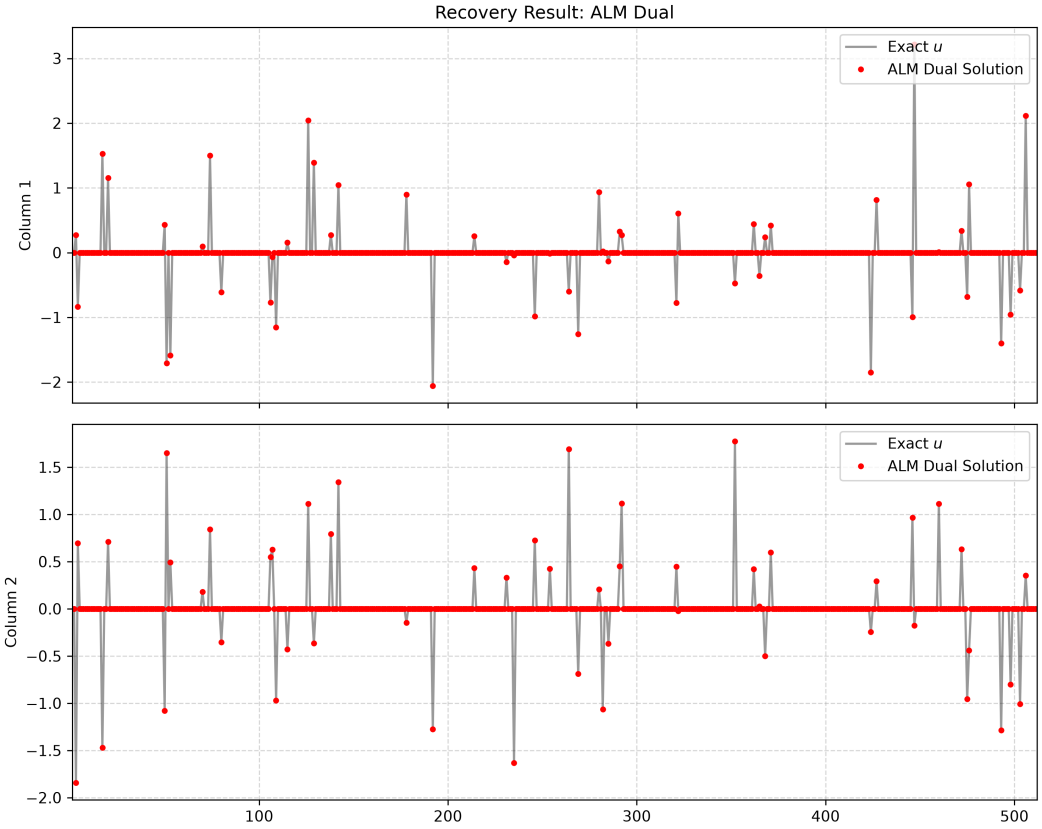

Recovery Result: SGD Primal
Exact u
SGD Primal Solution
Column 1
Column 2

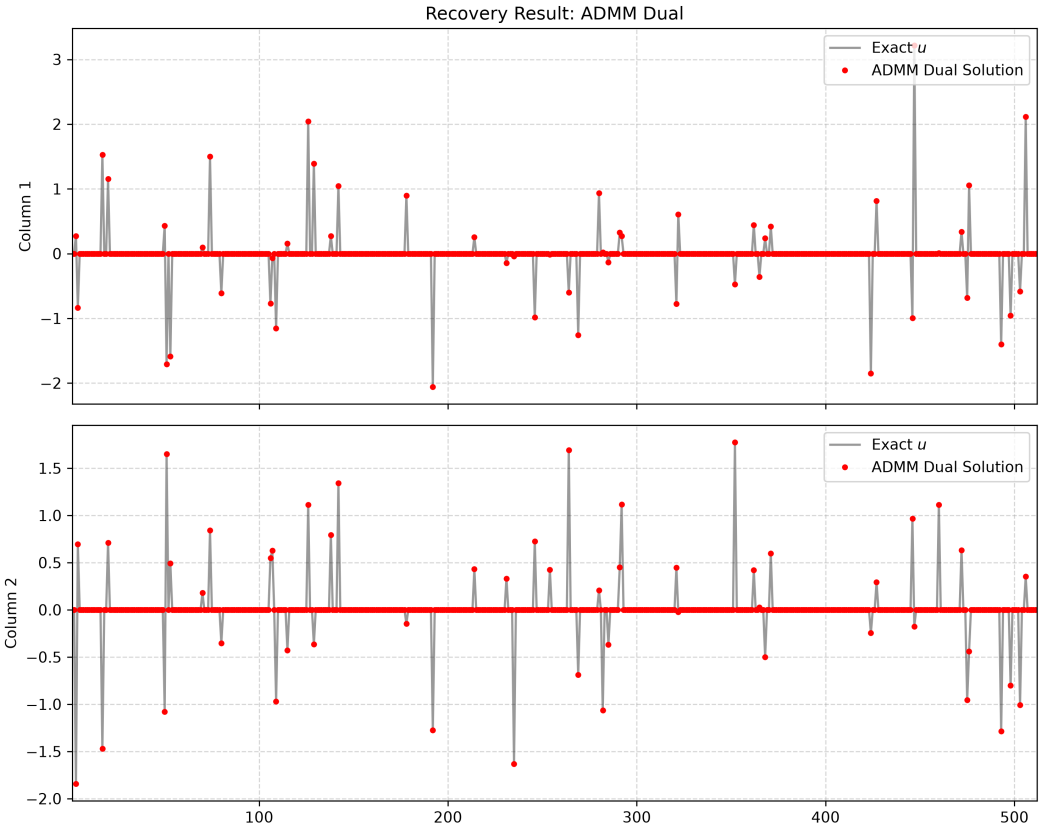

Recovery Result: GD Primal
Exact u
GD Primal Solution
Column 1
Column 2

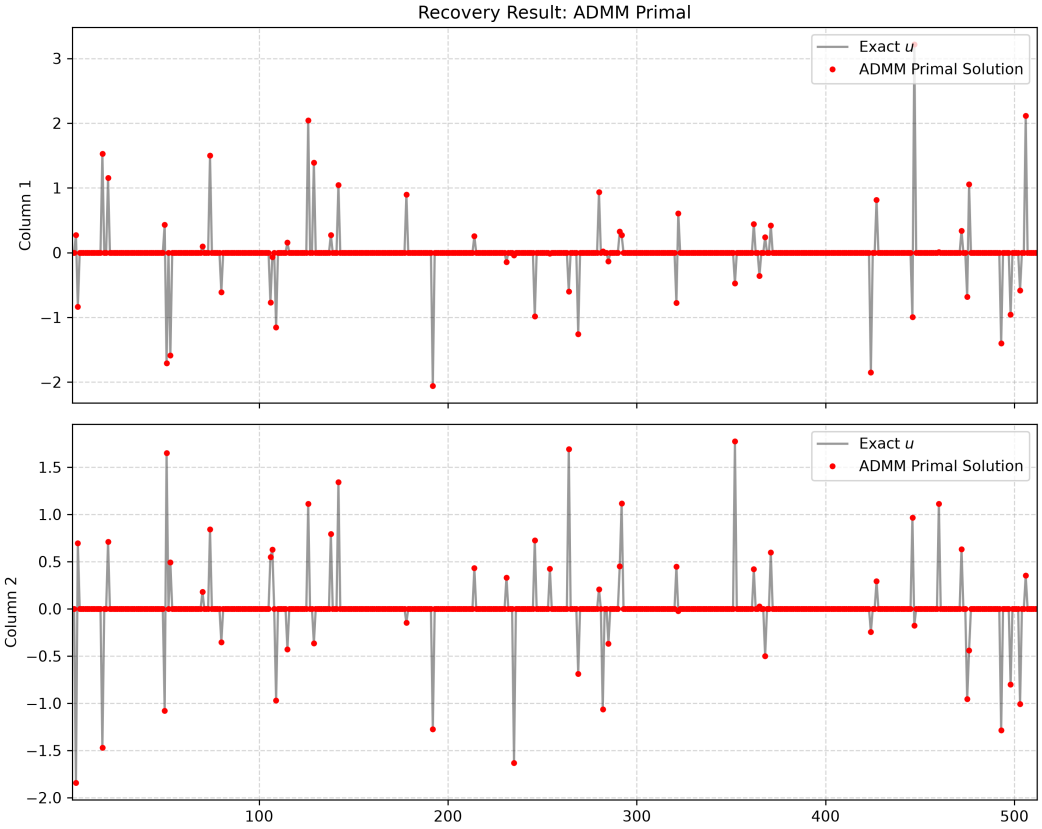

Recovery Result: FGD Primal
Exact u
FGD Primal Solution
Column 1
Column 2

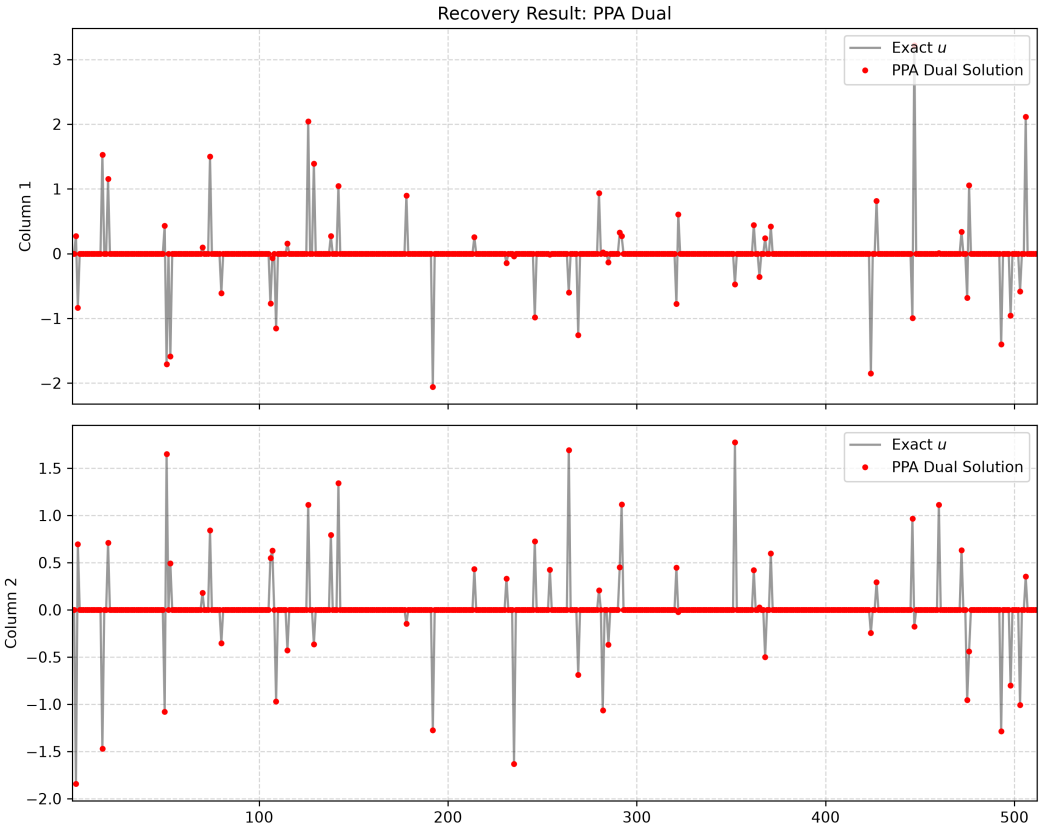

Recovery Result: ProxGD Primal
Exact u
ProxGD Primal Solution
Column 1
Column 2
100
200
300
400
500

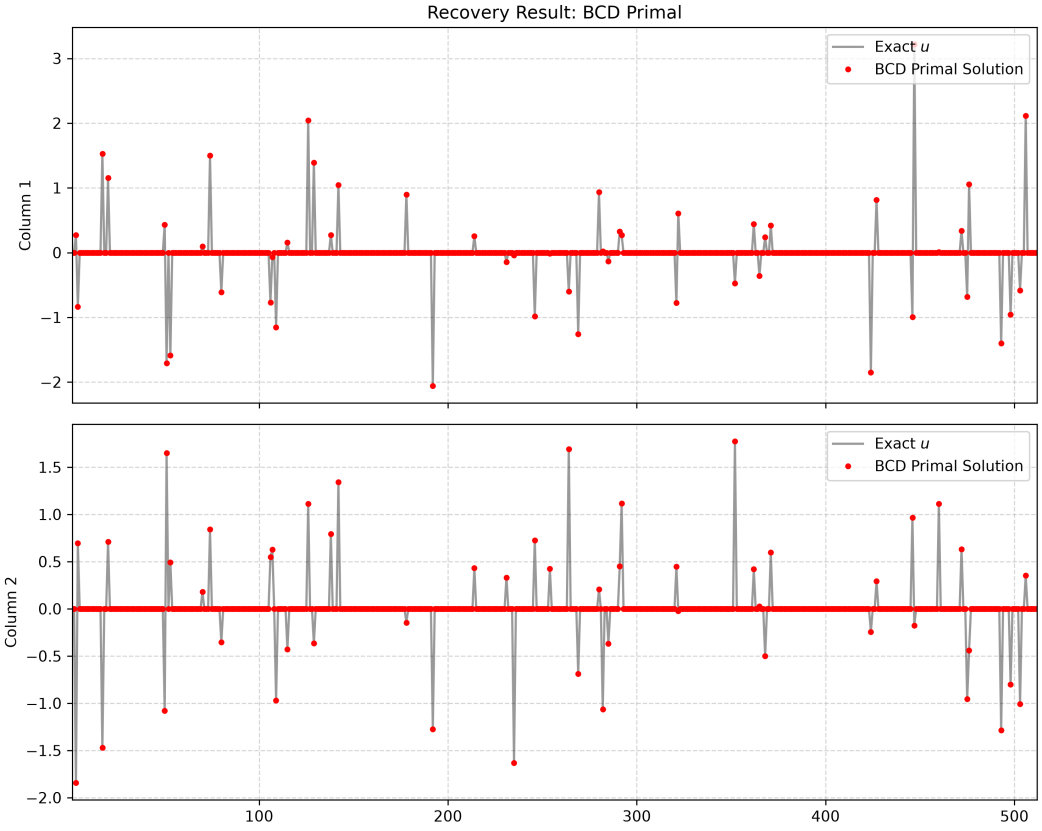

Recovery Result: FProxGD Primal
Exact u
FProxGD Primal Solution
Column 1
Column 2
100
200
300
400
500


Recovery Result: ALM Dual
Exact u
ALM Dual Solution
Column 1
Column 2
100
200
300
400
500


Recovery Result: ADMM Dual
Exact u
ADMM Dual Solution
Column 1
Column 2
100
200
300
400
500


Recovery Result: ADMM Primal
Exact u
ADMM Primal Solution
Column 1
Column 2
100
200
300
400
500


Recovery Result: PPA Dual
Exact u
PPA Dual Solution
Column 1
Column 2
100
200
300
400
500


Recovery Result: BCD Primal
Exact u
BCD Primal Solution
Column 1
Column 2
3
2
1
0
−1
−2
1.5
1.0
0.5
0.0
−0.5
−1.0
−1.5
−2.0
100
200
300
400
500